隊長：R06922002 姚嘉昇　組員：R06942054 潘仁傑、R06522620 王仁蔚

分工表

	1-1 Part1	1-1 Part2	1-2 Part1	1-2 Part2	1-2 Part3	1-2 Bonus	1-3 Part1	1-3 Part2	1-3 Part3	1-3 Bonus	report
姚嘉昇 R06922002	■	■		■	■		■	■	■	■	
王仁蔚 R06522620			■		■	■			■		
潘仁傑 R06942054	■	■									■

HW1-1　Part1　Simulate a Function

1. Describe the models you use, including the number of parameters (at least two models) and the function you use. (0.5%)

   以下 model 之數字是每一層 Dense 的數量

   Model0　: 1→5→10→10→10→10→10→5→1　Total parameters: 571

   Model1　: 1→10→18→15→4→1　Total parameters: 572

   Model2　: 1→190→1　Total parameters: 571

   Function1　: sin(5 * pi * x) / (5 * pi * x)

   Function2　: sgn(sin(5 * pi * x))

   Domain　: `np.linspace(0.0001, 1.0, num=10000)`

   ```
   loss='mse', optimizer='adam', batch_size = 128, epochs = 20000
   ```

2. In one chart, plot the training loss of all models. (0.5%)

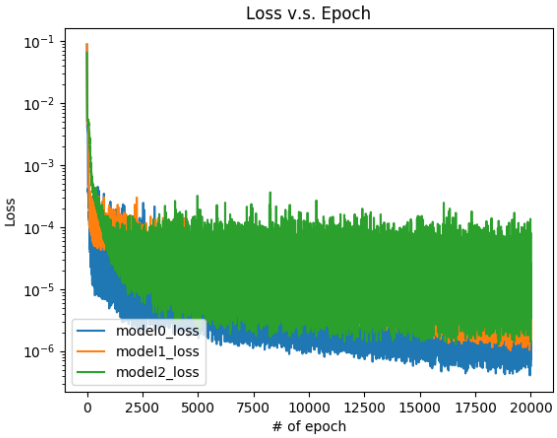

Function1

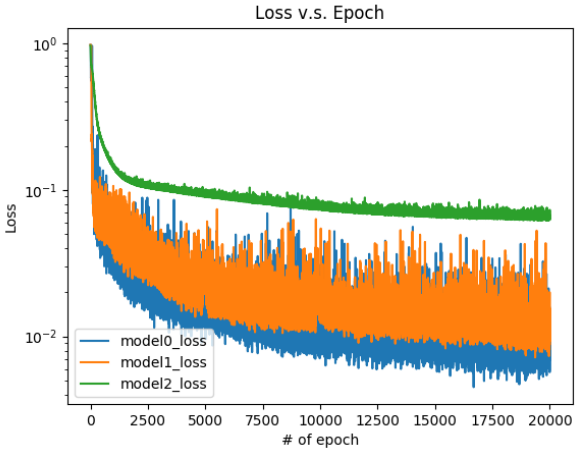

Function2

3. In one graph, plot the predicted function curve of all models and the ground-truth function curve. (0.5%)

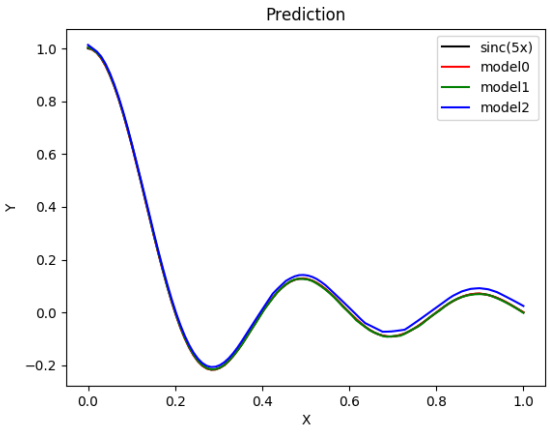

Function1

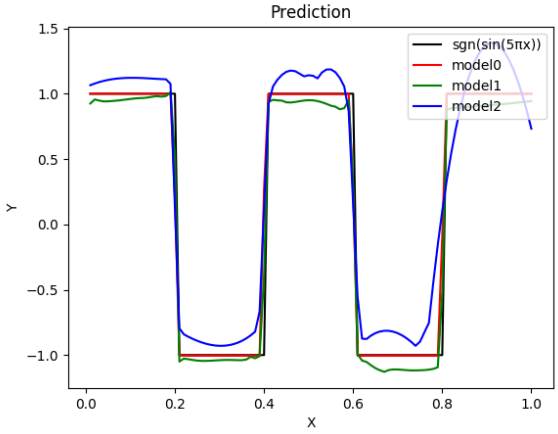

Function2

4. Comment on your results. (1%)

在第 2 點的兩張圖中，我們可以發現，雖然在訓練的過程中三個 model 的 loss 曲線會震盪，但 model0 的震盪的 loss 最低值都比起其他兩者來的低，model2 震盪的 loss 最高值在 2500 個 epoch 後都會比其他兩者來的高。

而在第 3 點左邊的圖中，三個 model 都非常接近 sinc(5x)這個函數，且在第 2 點左邊的圖中，三者的 loss 都在 10 的-4~-5 次方中，因此我們認為這三種 model 都有足夠的能力學習這個函數。

第 3 點右邊的圖中，最深的 model0 完全與目標函數重疊，loss 最低值在 10 的-2 次方左右；最淺胖的 model2 與目標函數看起來相差甚遠，且其 loss 比 model0 高了十倍，因此在這個函數的學習上，我們觀察到同參數但較深的 model 有更好的表現。

5. Use more than two models in all previous questions. (bonus 0.25%)
如第 1 點，我們使用了三個 model

6. Use more than one function. (bonus 0.25%)
如第 1 點，我們使用了兩個 function

HW1-1 Part2 Train on Actual Tasks

1. Describe the models you use and the task you chose. (0.5%)

CIFAR10

Model0: CNN(49, (5, 5)) + Dense(512) + Dense(10) paramters:1,238,678

Model1: CNN(49, (3, 3)) + CNN(49, (3, 3)) + Dense(512) + Dense(10) paramters:1,257,984

Model2: CNN(32, (3, 3)) + CNN(32, (3, 3)) + CNN(64, (3, 3)) + CNN(64, (3, 3)) + Dense(512) + Dense(10) paramters:1,250,858

```
batch_size = 32, epochs = 100, optimizer = rmsprop(lr=0.0001, decay=1e-6)
loss = 'categorical_crossentropy'
```

MNIST

Model0: CNN(17, (3, 3)) + desne(10) parameters: 133,460

Model1: CNN(12, (5, 5)) + CNN(16, (5, 5)) + desne(10) parameters: 130,578

Model2 CNN(8, (3, 3)) + CNN(12, (3, 3)) + CNN(16, (3, 3)) + desne(10) parameters: 128,150

```
batch_size = 128, epochs = 100, activation='selu', padding='SAME'
loss = 'categorical_crossentropy', optimizer = 'adam'
```

2. In one chart, plot the training loss of all models. (0.5%)

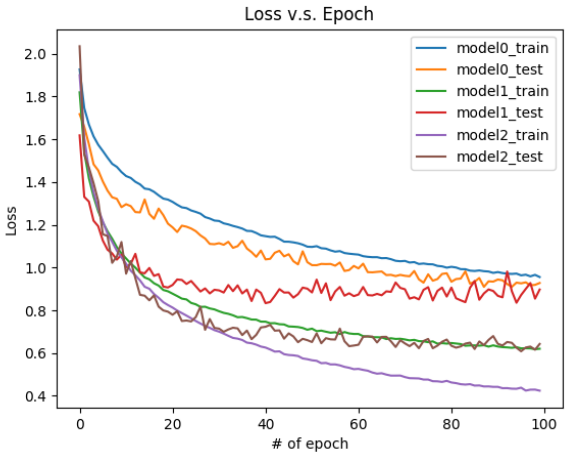

CIFAR10

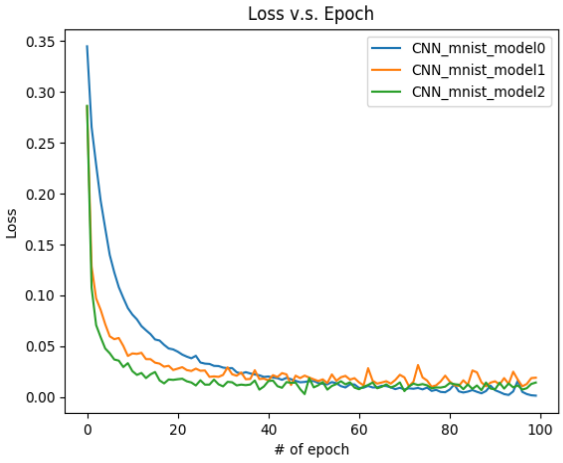

MNIST

3. In one chart, plot the training accuracy. (0.5%)

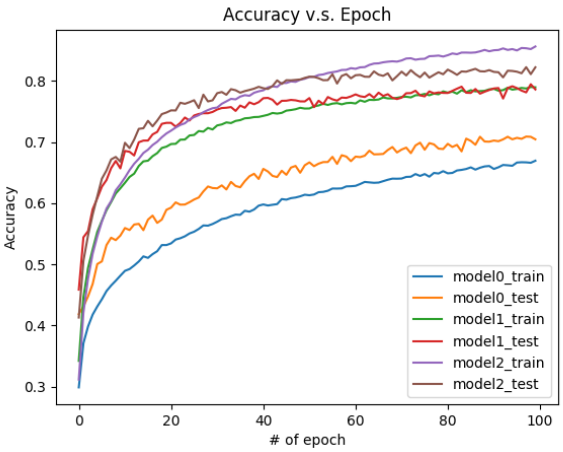

CIFAR10

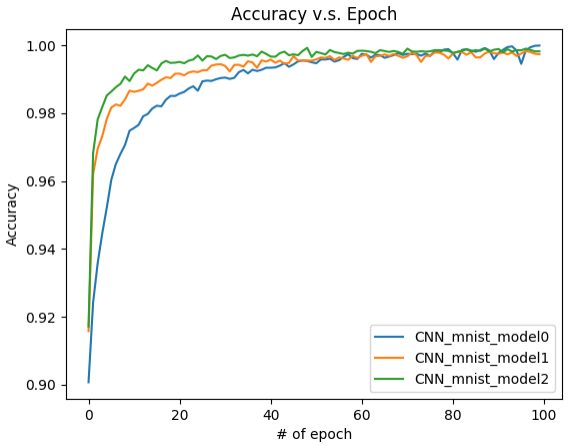

MNIST

4. Comment on your results. (1%)

在第 2、3 點的左圖。我們可以觀察到 loss 排序不論是 training 或 testing 都是最深的 model2 最，最寬胖的 model0 最高；acc 也是最深的表現最好，最胖的表現最差，因此在 CIFAR10 上，比較深的 model 表現較寬的 model 好。

但在 2、3 點的右圖，我們並沒有辦法非常清楚的區分其 loss 跟 acc 的排序，但其三個 model 的 loss 都非常接近零且 acc 非常接近 1，因此推判這三個 model 皆有能力解決 MNIST 手寫辨識的問題。

雖然 loss 跟 accuracy 三種 model 最後都能達到一樣好的效能 但是最深的 model 能夠比其他兩個更早先收斂在高 acc 低 loss。

5. Use more than two models in all previous questions. (bonus 0.25%)

   如第一點，我們使用三個 mdoel

6. Train on more than one task. (bonus 0.25%)

   如第一點，我們使用兩個 task

HW1-2 Part 1 Visualize the optimization process.

1. Describe your experiment settings. (The cycle you record the model parameters, optimizer, dimension reduction method, etc) (1%)

   Task : MNIST

   Model : Dense(128) + Dense(128) + Dense(10)

   `loss='categorical_crossentropy', optimizer='adam', batch_size=64`

   每一輪的 epochs=30，每三個 epoch 儲存一個 model，每一輪 30 個 epoch 共存 10 個 model，總共做八次，共 80 個 model

   使用 PCA 降維

2. Train the model for 8 times, selecting the parameters of any one layer and whole model and plot them on the figures separately. (1%)

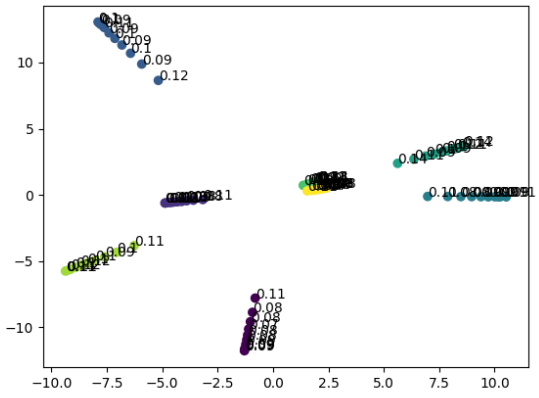

Layer1

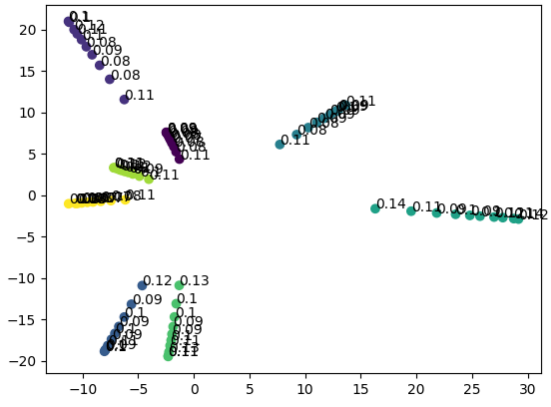

Whole Layer

3. Comment on your result. (1%)

   根據上面兩張圖，不論是選擇 layer 1 或是整個 model 的 parameter，八次訓練的 weight 做 PCA 降維後，因為每次 initial weight 不同，所以八組 weight 分布在不同地方，而不同起始點都能都收斂到足夠好的 min loss，而可以確定的一點就是圖的正中央是 Loss 高的，因為所有 weight 都往外跑。

HW1-2 Part 2 Observe gradient norm during training.

1. Plot one figure which contain gradient norm to iterations and the loss to iterations. (1%)

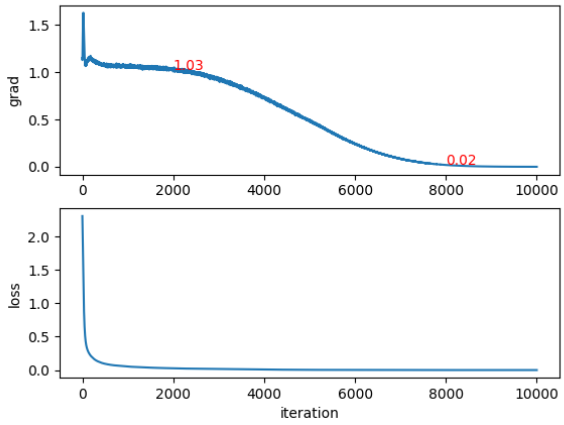

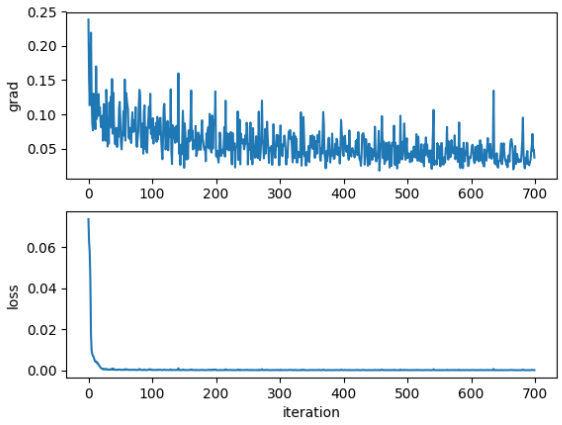

MNIST SINC

2. Comment your result. (1%)

根據 gradient norm to iterations and the loss to iterations 兩張圖，我們可以觀察 Loss 及 iteration 的圖，訓練後期的 loss 都已經收斂至 0，按照 gradient decent 的概念，直觀會認為 gradient 應該已經收斂到 0，也就是 local minimum，但我們拉出 grad 並作圖的話，我們發現其實 gradient 並不會等於 0，左圖是下降，直到 8000 個 epoch 後才趨近 0，而右圖則是持續地在 0.05~015 震盪。

HW1-2 Part 3 What happens when gradient is almost zero?

1. State how you get the weight which gradient norm is zero and how you define the minimal ratio. (2%)

設定：

Task : Y = `sinc(5*X)`

Domain : X = `np.linspace(0.0001, 1.0, num= 5000)`

Model : Dense(1) + Dense(5) + Dense(10) + Dense(10) + Dense(5) + Dense(1)

訓練方式：loss_func 用 MSE 訓練 64 個 epoch 後，將 loss_func 改成 epcoh_grad_g 繼續訓練 1024 個 epoch，若 epcoh_grad_g < 5e-3，則 early sotp

Weight 偏移方式 ：每個 weight 隨機加上一個-1~+1 的 random 值

Minimal ratio 定義 ：偏移後的 loss 比原本高的個數除上總個數

2. Train the model for 100 times. Plot the figure of minimal ratio to the loss. (2%)

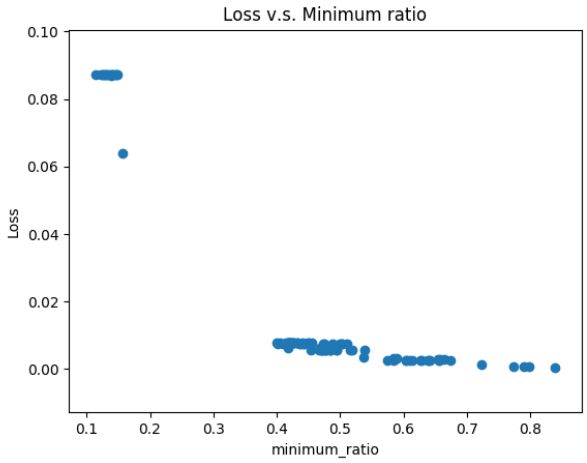

3. Comment your result. (1%)

根據上圖，loss 在 0.09 附近時(圖左上方)，minimal_ratio 約莫在 0.1 左右，也就是說，附近的點的 loss 比 0.09 大的比例只有一成；同理 loss 在 0 附近時(圖右下方)，minimal_ratio 約 0.7 到 0.85 之間，比例約八成。

我們的實驗結果顯示當 loss 越低時，minimum_ratio 越高，也就是 ratio 越高越靠近 local minimal。minimal ratio 越低則代表這個點有可能是 saddle point，所以 loss 才會偏高。

HW1-2 Bonus (1%)

1. Use any method to visualize the error surface.

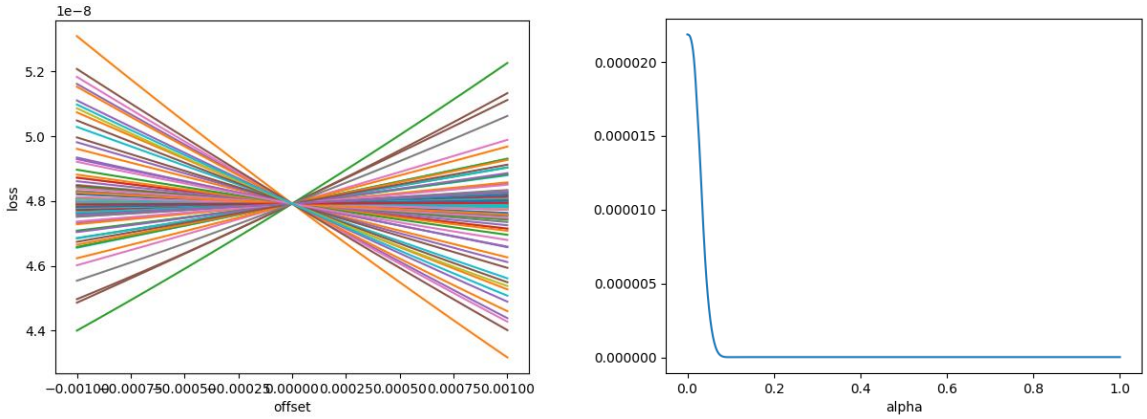

2. Concretely describe your method and comment your result.

我們使用 HW1-2 Part 3 的 model 架構，並嘗試了兩種 visualize the error surface 的方法：

- 第一種(上左圖)：抽取訓練過的 model weights，依次對每一個參數加上 offset -0.001~0.001，每一個參數得到一條 loss 對其參數做 offset 的直線。根據此圖，我們可以發現各個參數加上正 offset 後，loss 有的上升，有的卻下降，可以推判 offset=0 的 loss 可能是落在 saddle point，若是落在 local minimum，不管在任何參數上做微量的 offset，loss 應當都會上升。

- 第二種(上右圖)：將最後的 model weights 跟初始的 model weights 做插指，alpha=0 時是初始的 model weights，alpha=1 時是 train 完的 model weights。也就是說，在高維空間中，初始的 weights 會筆直地往 final 的 weights 前進，我們將圖 zoom in 後，一值都是遞減而沒有像助教投影片中會震盪，也許是我們初始的 weight 剛好落在一個平滑的曲面，其 gradient 恰好朝向 final weights 的方向，也許是我們的 model 太過簡易，loss 曲線不夠複雜。

HW1-3 Part 1 Can network fit random variables?

1. Describe your settings of the experiments. (e.g. which task, learning rate, optimizer) (1%)
   MNIST
   batch_size = 128
   optimizer=Adam(lr=0.001)
   Activation('selu')
   Model: CNN(16, (3, 3))+ CNN(16, (3, 3)) + CNN(32, (3, 3)) + Dense(512) + Dense(10)
   paramters:1,238,678

2. Plot the figure of the relationship between training and testing, loss and epochs. (1%)

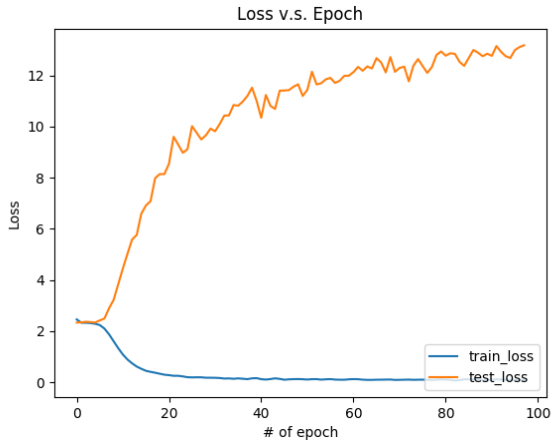

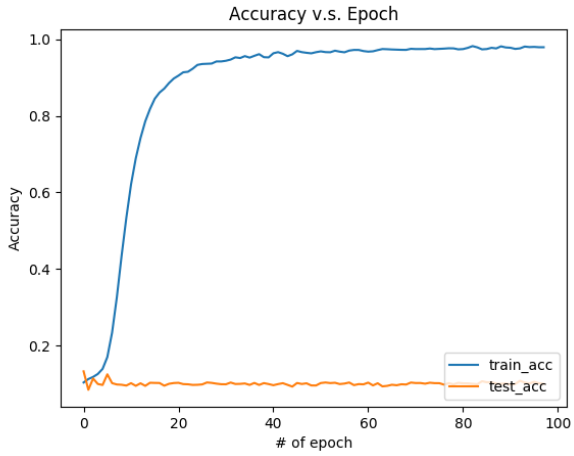

HW1-3 Part 2 Number of parameters V.S. Generalization

1. Describe your settings of the experiments. (e.g. which task, the 10 or more structures you choose) (1%)
   MNIST、batch_size = 1024、 `epochs = 20`
   50 個 model：每個 model 都有一層 CNN，且 kernel_size=(3, 3)，但第 i 個 model 的 CNN 使用 i + 1 個 filter，每個 model 最後接 Dense(10)
   `loss='categorical_crossentropy', optimizer='adam'`
2. Plot the figures of both training and testing, loss and accuracy to the number of parameters. (1%)

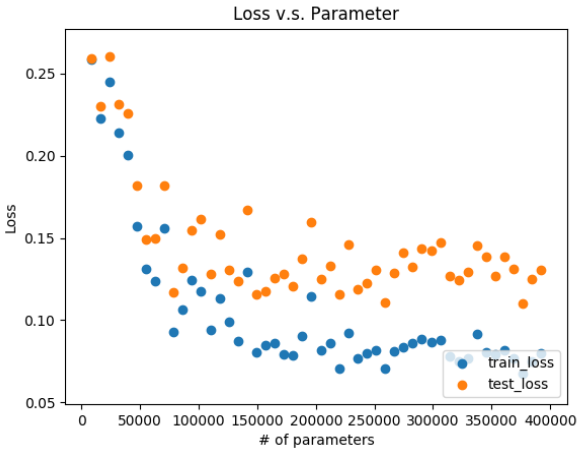

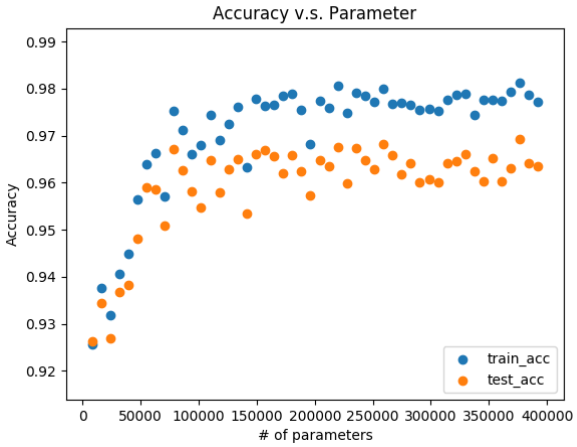

3. Comment your result. (1%)

根據上圖，當 parameters 越多時，不論 train or test 的 loss 就逐漸下降，超過 50000 之後，就沒有下降趨勢。當 parameter 數超過五萬，可以判定 model 的學習能力已經能夠處理 MNIST 這個 dataset 的問題，也沒有因為 parameter 太多而 Overfitting。

HW1-3 Part 3 Flatness V.S. Generalization

1. Part 1

1.1 Describe the settings of the experiments (e.g. which task, what training approaches) (0.5%)

使用 MNIST，架構為 CNN(16, (3,3), selu) + Dense(10)

所有 model 都使用 `loss='categorical_crossentropy'`，`optimizer='adam'`

`Batch Size = 64 v.s. 1024` 各一個 `model`，並使用插指法繪圖

`Learning Rate = 1e-3 vs. 1e-2` 各一個 `model`，並使用插指法繪圖

1.2 Plot the figures of both training and testing, loss and accuracy to the number of interpolation ratio. (1%)

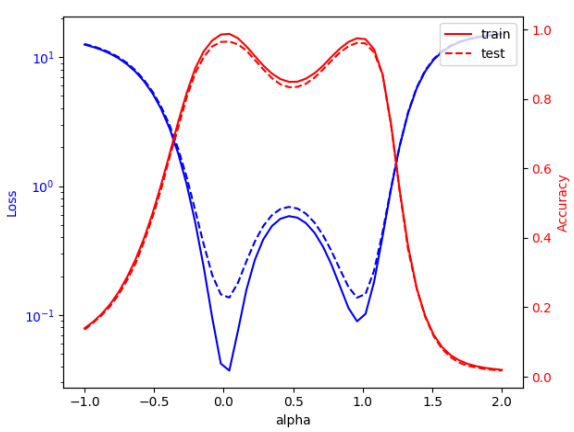

Batch Size = 64 v.s. 1024

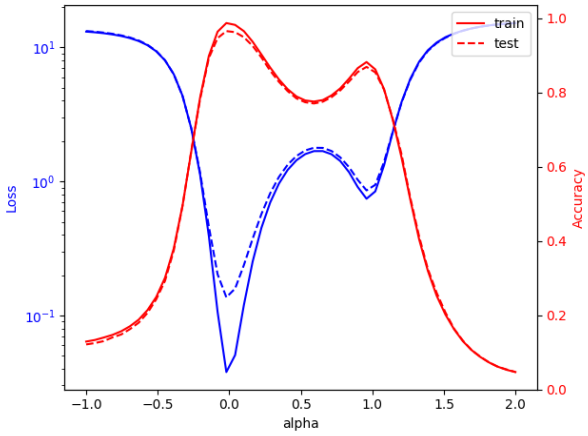

Learning Rate = 1e-3 vs. 1e-2

1.3 Comment your result. (1%)

上左圖在 alpha=0 時是 Small Batch Size，alpha=1 是 Large Batch Size。，上右圖在 alpha=0 時是 Small Learning Rate，alpha=1 是 Large Learning Rate。

以左圖為例，在 training 時小的 Batch Size 的 loss 比起大的 Batch Size 來的低，但並沒有向老師上課所說小的 Batch Size 會比較寬，大的 Batch Size 會比較尖，但其 testing 的 loss，比起 training 的 loss 都來的高，如同老師上課所說，可能是 testing 的 loss 曲線會跟 loss 相像但會在某個維度有些微偏移。

2. Part 2 :

1.1 Describe the settings of the experiments (e.g. which task, what training approaches) (0.5%)

TASK ：MNIST and CIFAR10

sensitivity 定義 ：Frobenius norm of gradients of loss to input

1.2 Plot the figures of both training and testing, loss and accuracy, sensitivity to your chosen variable. (1%)

MNIST

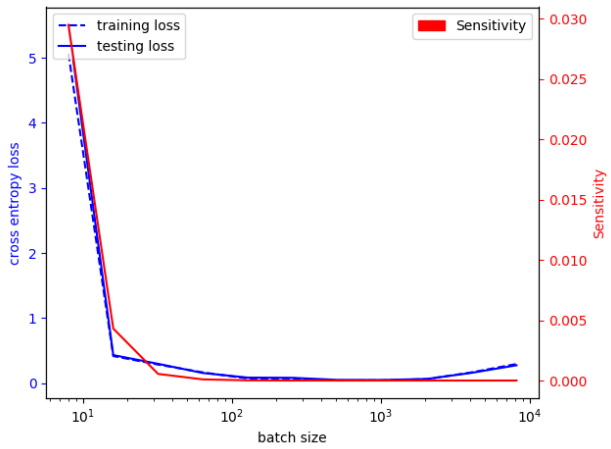

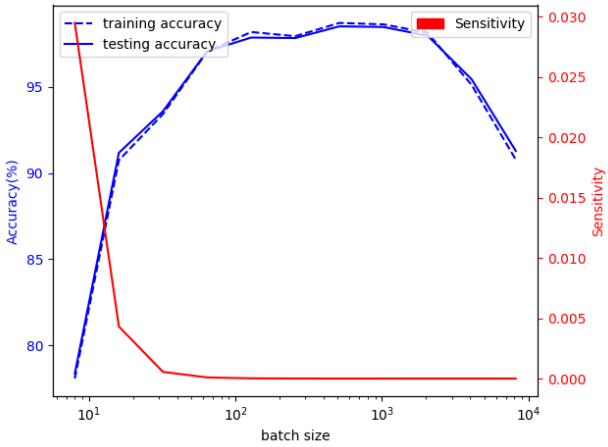

CIFAR-10

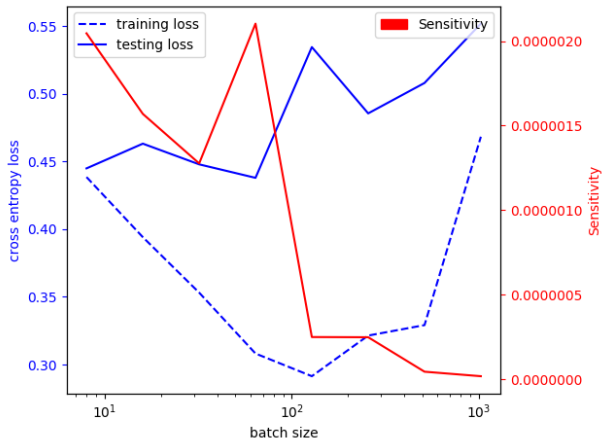

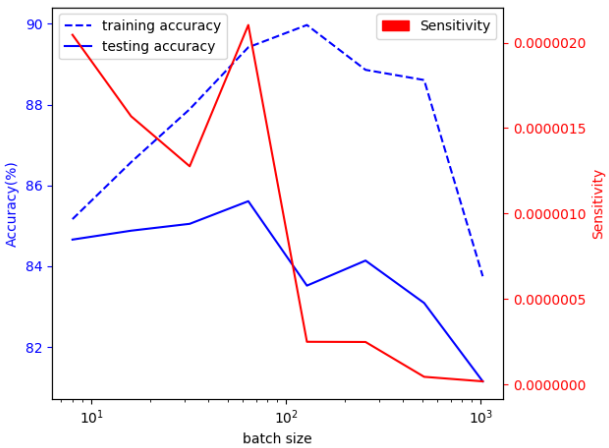

1.3 Comment your result. (1%)

以上四張圖可以看出，當 Batch Size 越來越大時，sensitivity 會趨近 0，也就是說這個 network 對 data 的敏感度越來越低，也可以觀察在 MNIST 及 CIFAR10 上當 batch Size 大到一定程度時 Acc 會開始降低。敏感度低意味著 model 較易受資料偏移影響，因此其 generalization 能力較強，理當在 training acc 和 testing acc 間的差距小，不過在 cifar-10 的圖上並沒有一定這樣表現，推測可能我們計算的是 loss 對 input 而非 output 對 input 所產生的敏感度。

3. Bonus : Use other metrics or methods to evaluate a model's ability to generalize and concretely describe it and comment your results.

我們計算 Sharpness 的方法是同老師投影片的 Definition2，在 train 完的 weights 附近加上 random offset，這些點最高的 Loss 與原本 Loss 相減即是我們的 sharpness，若 sharpness 越大則該 model 之 weight 落在較尖陡的 local minimum。

每個 model epoch 都是 20，model 架構為一層 CNN+Dense。在每個 model 的 weight 附近採樣 1000 個樣本點，範圍是 epsilon = 1e-4。下圖為 MNIST 上計算 loss&sharpness v.s. batch_size 以及 accuracy and sharpness v.s. batch_size，從圖可明顯發現，當 batch size 越大時，sharpness 值就越大，代表收斂到非常陡峭的 local minimum，但 batch size 在 10~1000 的範圍內 sharpness 明顯震盪，推測可能是因為偏移量太大或是，weight 的每個維度都有 random offset，造成 random offset 過的 weight 跳出 local minimum 所在之位置。